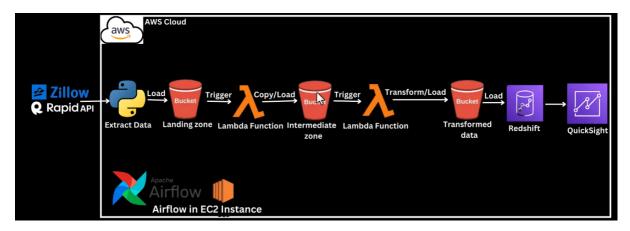
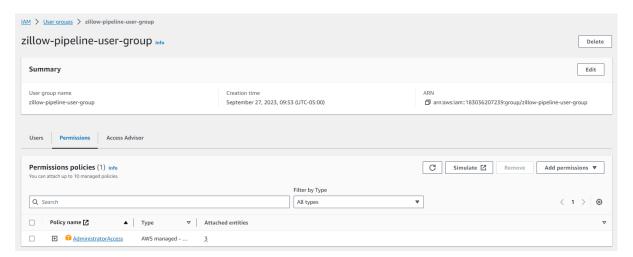
Architecture



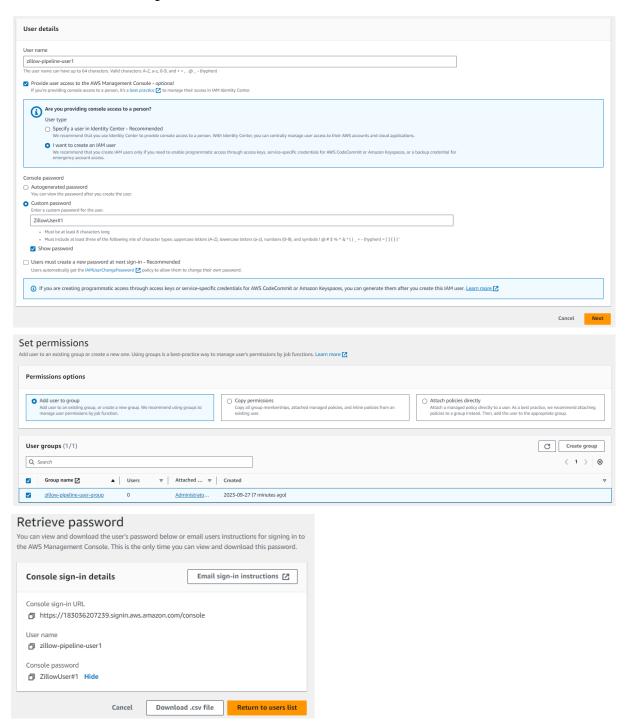
DAG TO BUILD



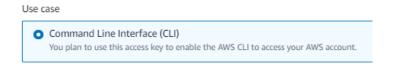
Primero, creamos un User Group para asignar permisos a los servicios que vamos a manejar. Para ello, ingresamos a IAM y creamos un grupo con permisos de Administrator Access.



Ahora debemos crear los usuarios. Para el primer usuario, habilitamos la opción de acceder a la consola de AWS. Le asignamos una contraseña.



Para este usuario creamos una access key que usaremos más adelante. Guardamos la key y el secret.

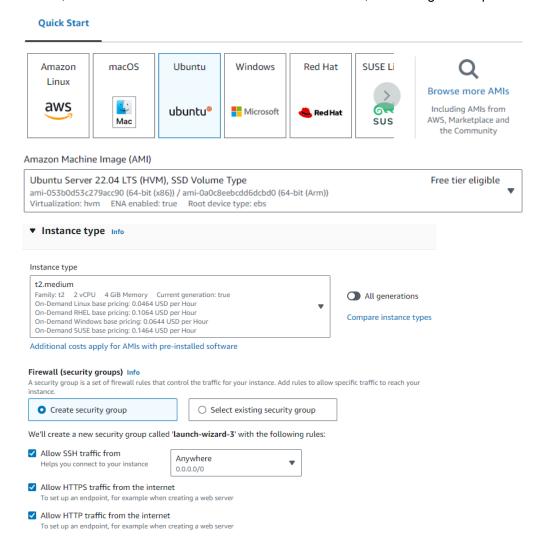


Utilizamos la sign-in URL para ingresar a la cuenta de nuestro user #1.

Sign in as IAM user

Account ID (12 digits) or account alias 183036207239 IAM user name zillow-pipeline-user1 Password Remember this account Sign in N. Virginia ▼ zillow-pipeline-user1 @ 1830-3620-7239 ▼

Ahora, dentro de esta cuenta creamos una instancia EC2, con los siguientes parámetros.



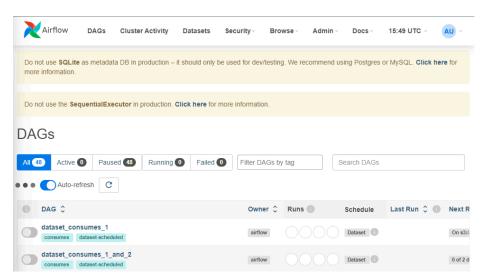
Adicionalmente creamos una key pair para conectarnos más adelante. Nuestra instancia ya está lista.



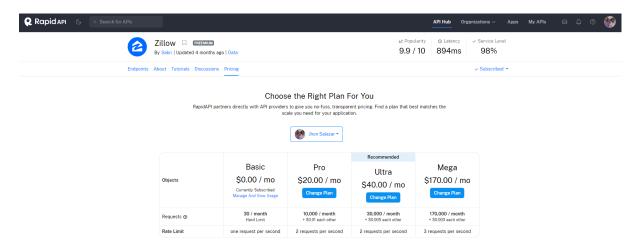
Nos conectamos e instalamos dependencias, creamos un entorno virtual y corremos airflow.

- 1. sudo apt update
- 2. sudo apt install python3-pip
- 3. sudo apt install python3.10-venv
- 4. python3 -m venv zillowpipeline_venv
- 5. source zillowpipeline_venv/bin/activate
 - 5.1. pip install --upgrade awscli
 - 5.2. pip install apache-airflow-providers-amazon
 - 5.3. sudo pip install apache-airflow
 - 5.4. airflow standalone

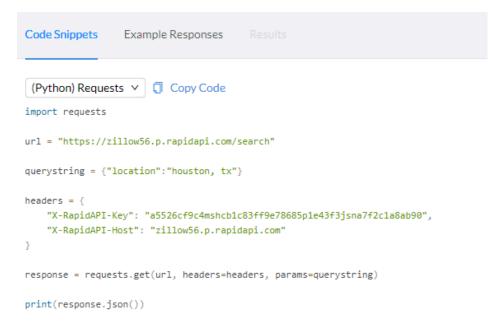
Finalmente iniciamos Airflow con la IP pública de nuestra instancia, a través del puerto 8080. Recordemos que se debe habilitar este puerto en el security group, usando Custom TCP.



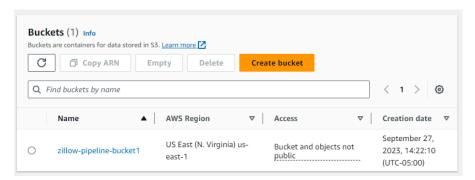
Nos dirigimos a RapidAPI y buscamos la API de Zillow.



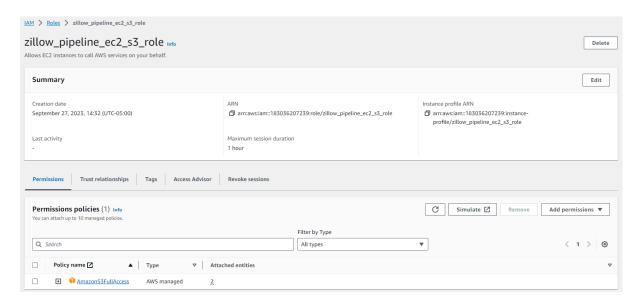
Utilizamos el código de request en Python para obtener los datos.



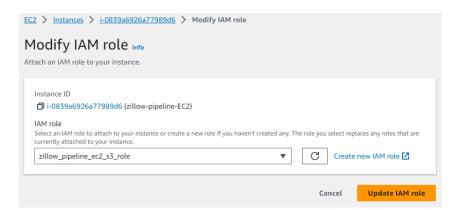
Creamos el task correspondiente a la extracción de datos provenientes de la API de Zallow. Luego creamos el bucket para almacenarlos.



Para conectarnos al S3 desde EC2 creamos un rol con full access.



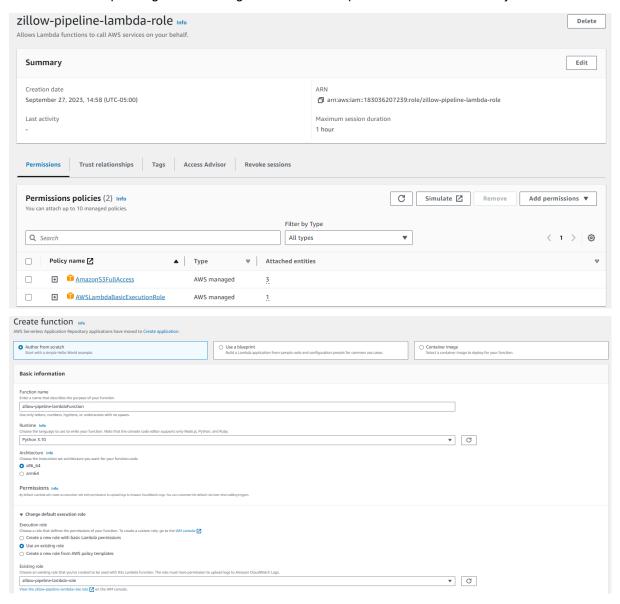
Modificamos el rol IAM en el EC2.

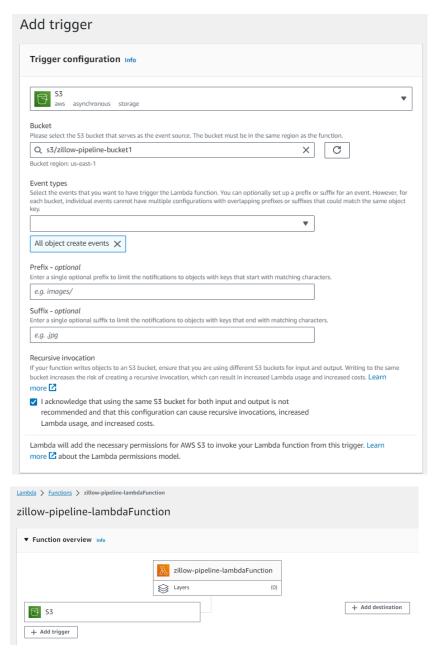


Hasta ahora el DAG va así.

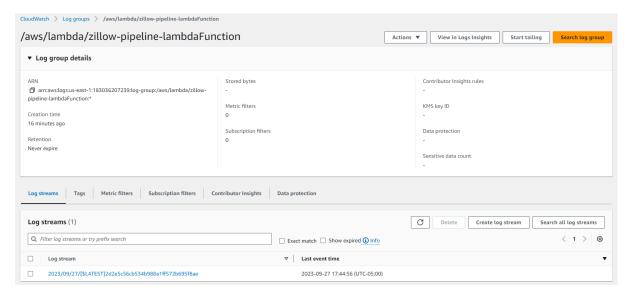


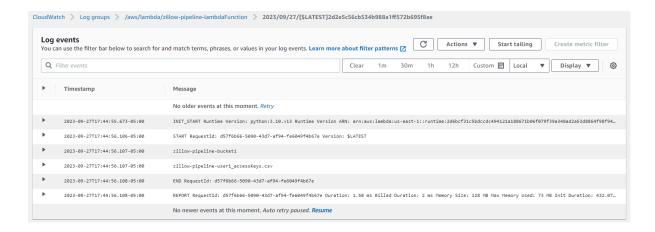
Creamos un rol para el servicio **Lambda**. Con el permiso AWSLambdaBasicExecutionRole, el servicio Lambda puede guardar sus logs en CloudWatch para saber cómo van las ejecuciones.



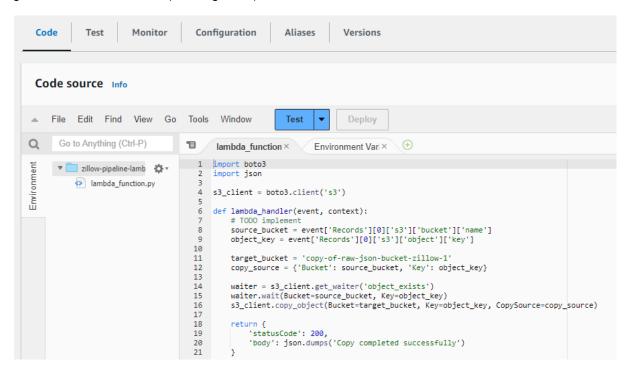


Probamos este trigger (*guardar cambios con el botón Deploy*) añadiendo un nuevo documento a nuestro S3, con el fin de obtener un log dentro de CloudWatch que nos permita ver ese movimiento.

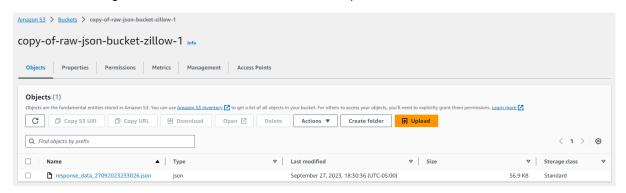




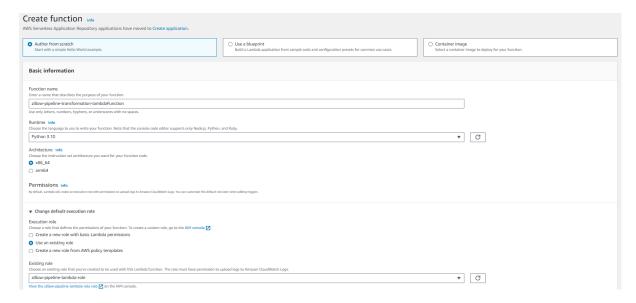
Iniciamos nuevamente el DAG y probamos nuestro trigger de Lambda, en este caso el archivo guardado en el bucket #1 (Landing Zone) debe ser enviado al bucket #2.



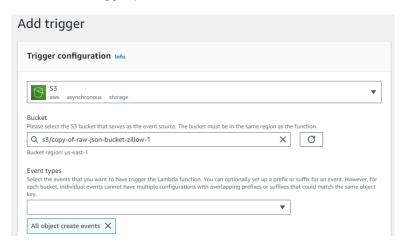
El archivo se carga correctamente en el bucket #2 correspondiente a Intermediate Zone.



Creamos una nueva función Lambda para transformar los datos.



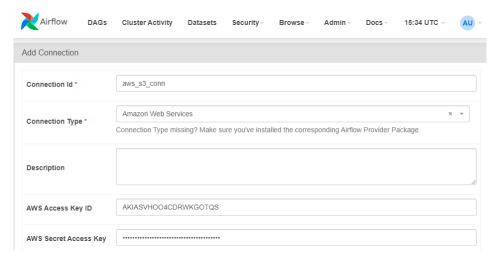
Añadimos un trigger para acceder a nuestro bucket #2.



Escribimos nuestro código para tomar los registros en formato json, seleccionar algunas columnas y subir el archivo csv al bucket #3 creado. A su vez, creamos un sensor de S3 para corroborar que nuestro archivo quedó cargado correctamente.

```
is_file_in_s3_available = S3KeySensor(
    task_id = 'tsk_is_file_in_s3_available',
    bucket_key = '{{ti.xcom_pull("tsk_extract_zillow_data_var")[1]}}',
    bucket_name = s3_bucket,
    aws_conn_id = 'aws_s3_conn',
    wildcard_match = False, # Set this to True if you want to use wildcards in the
    timeout = 60, # Optional: Timeout for the sensor (in seconds)
    poke_interval = 5, # Optional: Time interval between S3 checks (in seconds)
)
```

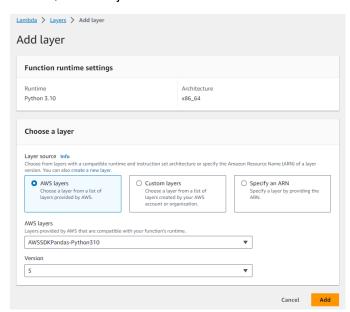
Creamos la conexión al servicio S3 en Airflow. Utilizamos la key y secret del user #1 que creamos anteriormente.



Ingresamos a las funciones Lambda y editamos el timeout hasta 5 min. En la sección Configuration.



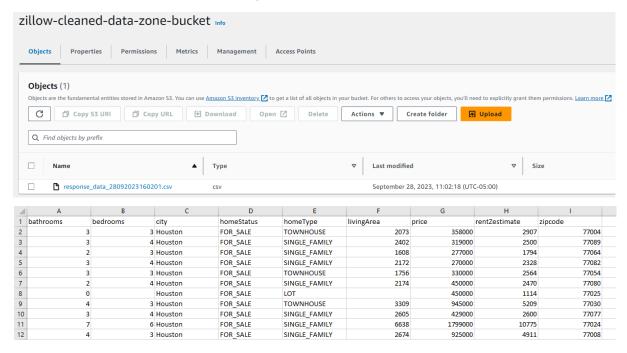
Ahora, en nuestra última función Lambda debemos crear un Layer para poder usar la dependencia Pandas, si no arrojará error.



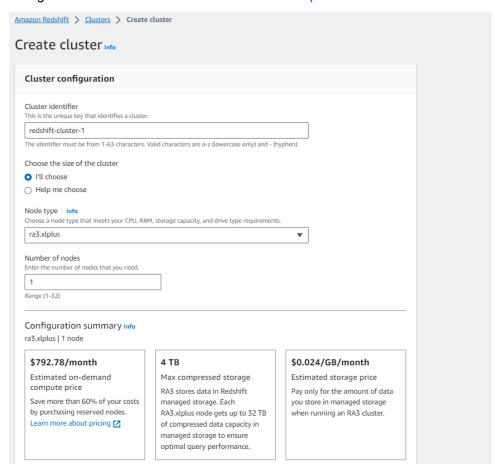
Corremos el DAG y se ejecuta correctamente.

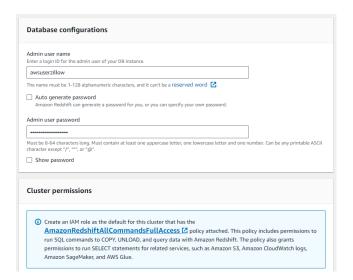


El archivo transformado en formato .csv queda almacenado en el bucket #3.

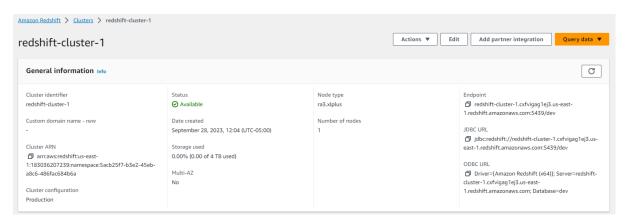


Como siguiente paso, creamos nuestro cluster dentro de Amazon Redshift usando la siguiente configuración. Se debe tener cuidado con el cobro por usar este servicio.

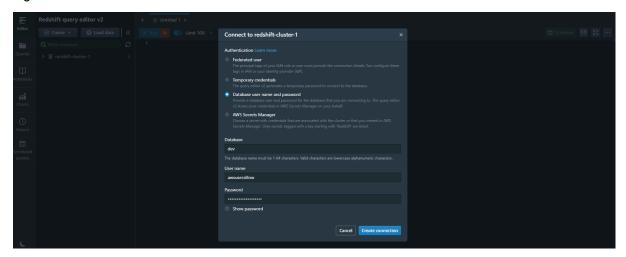




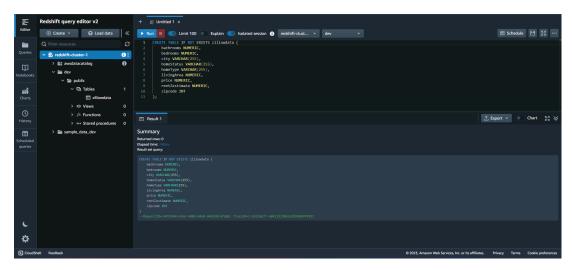
Nuestro cluster se crea correctamente.



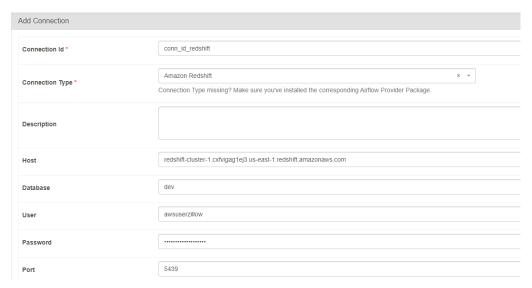
Dentro de las herramientas de Amazon Redshift tenemos el *Query editor v2*. Lo seleccionamos e ingresamos al cluster con nuestras credenciales.



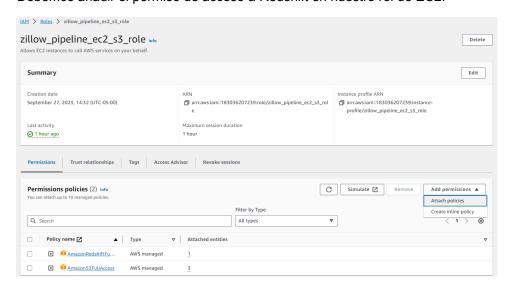
Se crea la tabla correspondiente, en la base de datos Dev en Redshift.



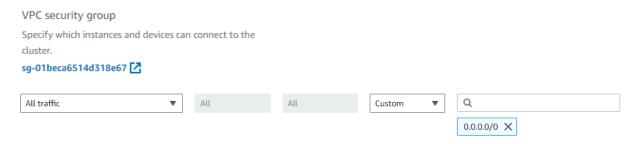
Luego, creamos la tarea (task) en nuestro DAG para poder tomar el archivo de nuestro bucket #3 y cargar esa información en la tabla de Redshift. Dentro de esta tarea debe haber una conexión establecida en Airflow. Usamos el endpoint del cluster y las credenciales.



Debemos añadir el permiso de acceso a Redshift en nuestro rol de EC2.



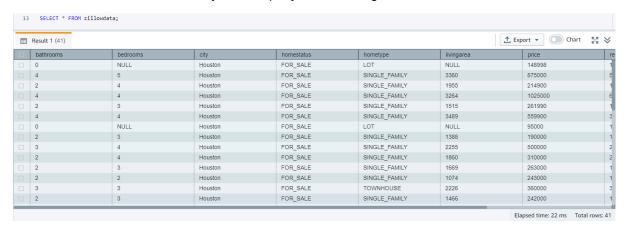
Para lograr una conexión exitosa con el servicio de Redshift debemos crear una *inbound rule* permitiendo el tráfico desde cualquier punto. Podemos limitar el acceso al permitir solo nuestra IP, pero en este caso no lo haremos así.



Corremos nuestro DAG y vemos que se ejecuta correctamente.



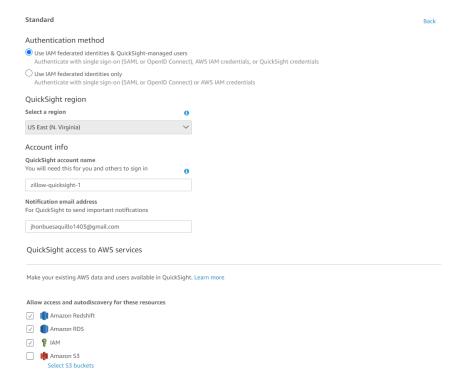
Consultamos la tabla en Redshift y vemos que ya se han cargado los datos del archivo .csv.



En caso de correr nuevamente nuestro DAG, se cargaran los datos nuevamente a nuestra tabla zillowdata, sin importar que estén duplicados.

Finalmente utilizamos el servicio QuickSight para visualizar nuestros datos. Elegimos la siguiente opción al momento de abrir el servicio.

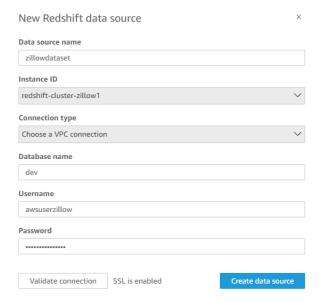
Sign up for Standard Edition here.



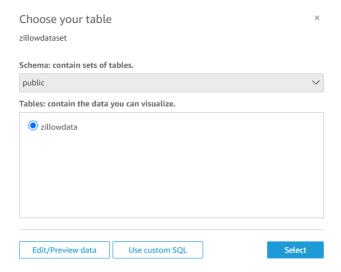
Creamos nuestra cuenta en QuickSight y nos ofrece la siguiente interfaz.



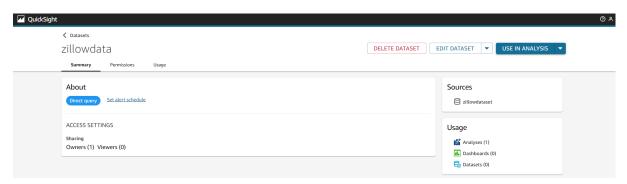
Vamos a la opción Datasets y creamos uno nuevo. Nuestra source es Redshift (Auto-discovered).



Seleccionamos nuestra tabla y nos vamos a Edit/Preview data.



Dentro de los datasets del servicio ya podemos ver el que hemos creado anteriormente. Ingresamos a *Use in Analysis*.



Dentro de esta herramienta podemos explorar las diferentes opciones que nos ofrece. Para este caso solo planteamos algunas gráficas sencillas para validar los datos de nuestra tabla zillowdata.

